

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
BACHARELADO EM TECNOLOGIA DA INFORMAÇÃO

PREDIÇÃO DE SALÁRIOS DA NBA UTILIZANDO DEEP LEARNING

SÉRGIO VICTOR DOS SANTOS DANTAS
NATAL/RN

1. INTRODUÇÃO

A National Basketball Association, conhecida popularmente pela sigla NBA, está situada na América do Norte e é considerada por muitos a principal liga de basquetebol profissional do mundo. Fundada em 1946, a organização consolidou-se como um gigante do entretenimento esportivo global. Atualmente, a liga é composta por 30 franquias estrategicamente espalhadas ao longo dos Estados Unidos e do Canadá, operando sob um modelo de negócio altamente competitivo e lucrativo. No cenário contemporâneo, a NBA conta com 589 jogadores de elite (conforme dados disponibilizados pela própria liga¹), cujos desempenhos em quadra são monitorados por métricas avançadas de performance que influenciam diretamente as negociações contratuais e a economia interna das equipes.

Avaliar com precisão o valor de mercado de um jogador da liga é uma tarefa difícil, especialmente considerando o teto salarial da temporada e a complexidade desse sistema que movimenta bilhões de dólares. Muitas franquias frequentemente assinam “contratos tóxicos” (pagam muito para quem produz pouco) ou deixam escapar talentos subvalorizados porque é humanamente e matematicamente complexo cruzar dezenas de métricas de volume e eficiência para chegar a um valor justo em dólares.

2. JUSTIFICATIVA

Nesse contexto, a utilização de um modelo de Deep Learning surge como uma solução robusta capaz de mitigar uma grande parcela desse problema. Através do processamento de grandes volumes de dados históricos e estatísticas avançadas, a rede neural pode ser treinada para identificar padrões complexos que métodos estatísticos tradicionais muitas vezes ignoram. Isso permite que o sistema estime um salário justo para o jogador baseando-se exclusivamente em sua produtividade real dentro das quadras, isolando fatores subjetivos ou inflacionários do mercado.

Para as equipes, a implementação de um modelo preciso significa não apenas a otimização do teto salarial, mas também uma vantagem estratégica na construção de elencos competitivos, permitindo montar times campeões sem estourar o orçamento limitado pela liga.

¹ <https://www.nba.com/players>

Desse modo, torna-se crucial a adoção de uma tecnologia de ponta que estime corretamente o preço de um jogador da NBA, garantindo a sustentabilidade financeira das franquias e a justiça na remuneração dos atletas de elite.

3. OBJETIVO

O objetivo geral deste trabalho é desenvolver e avaliar um modelo de Aprendizado de Máquina (AM) — baseado em Redes Neurais Artificiais — capaz de prever o salário justo de jogadores da NBA, fundamentando-se apenas em suas métricas de desempenho e perfil estatístico. Os objetivos específicos compreendem:

- Coletar e realizar o pré-processamento de um dataset com estatísticas e salários de jogadores da liga entre 2017 e 2025;
- Construir e treinar uma arquitetura de Multilayer Perceptron (MLP) para encontrar padrões entre o desempenho e a remuneração do jogador;
- Avaliar a precisão e a capacidade de generalização do modelo;
- Analisar as divergências entre as previsões do modelo e os salários reais para identificar ineficiências de mercado, como contratos supervalorizados ou subvalorizados.

4. METODOLOGIA

Para o treinamento do modelo, foi utilizado um dataset disponibilizado no Kaggle². Embora o conjunto de dados original contivesse registros de 2010 a 2025, foi realizado um recorte estratégico para utilizar apenas as estatísticas e salários compreendidos entre os anos de 2017 e 2025.

A escolha desse recorte temporal justifica-se pelo fato de que, a partir de 2017, o basquete praticado na liga passou por uma transformação caracterizada por um aumento expressivo no volume de arremessos de 3 pontos e uma grande elevação no teto salarial da NBA. Esses fatores tornam os dados anteriores a este período menos comparáveis e representativos para o treinamento do modelo atual.

² <https://www.kaggle.com/datasets/ratin21/nba-player-stats-and-salaries-2010-2025>

A abordagem de Aprendizado Profundo foi escolhida por sua eficácia em modelar relações complexas e não lineares entre desempenho e remuneração. Diferente de modelos tradicionais, as Redes Neurais capturam interações sutis entre métricas de eficiência e impacto tático, permitindo previsões mais precisas sobre ineficiências salariais na liga. Além disso, o problema abordado neste trabalho é classificado como uma tarefa de regressão, uma vez que o objetivo central do modelo é prever o valor contínuo e exato do salário dos jogadores com base em seu perfil estatístico.
















4.1. EXPLORAÇÃO DOS DADOS

Ao começar a explorar os dados, foram realizadas análises univariadas e multivariadas. Foi possível notar que a distribuição das variáveis numéricas apresentava uma cauda longa, o que acontece principalmente por causa dos superastros da liga, cujas estatísticas fogem bastante dos padrões convencionais. Ademais, o salário foi correlacionado com todos os outros atributos numéricos, a fim de tentar encontrar uma boa correlação. O dataset possui as seguintes colunas, listadas na Tabela 1, separados categoricamente:

Atributo	Significado	Categoria
<i>Player</i>	Nome	Valores cadastrais
<i>Salary</i>	Salário	Valores cadastrais
<i>Year</i>	Ano (temporada)	Valores cadastrais
<i>Pos</i>	Posição	Valores cadastrais
<i>Age</i>	Idade	Valores cadastrais
<i>Team</i>	Time	Valores cadastrais
<i>G</i>	Jogos	Totais acumulados
<i>GS</i>	Jogos iniciados como titular	Totais acumulados
<i>MP</i>	Minutos jogados	Média por jogo
<i>FG</i>	Arremessos convertidos	Média por jogo

<i>FGA</i>	Arremessos tentados	Média por jogo
<i>FG%</i>	Porcentagem de acerto nos arremessos	Taxas
<i>3P</i>	Arremessos de 3 pontos convertidos	Média por jogo
<i>3PA</i>	Arremessos de 3 pontos tentados	Média por jogo
<i>3P%</i>	Porcentagem de acerto nos arremessos de 3 pontos	Taxas
<i>2P</i>	Arremessos de 2 pontos convertidos	Média por jogo
<i>2PA</i>	Arremessos de 2 pontos tentados	Média por jogo
<i>2P%</i>	Porcentagem de acerto nos arremessos de 2 pontos	Taxas
<i>eFG%</i>	Porcentagem efetiva nos arremessos	Taxas
<i>FT</i>	Lances livres convertidos	Média por jogo
<i>FTA</i>	Lances livres tentados	Média por jogo
<i>FT%</i>	Porcentagem de acerto nos lances livres	Taxas
<i>ORB</i>	Rebotes ofensivos	Média por jogo
<i>DRB</i>	Rebotes defensivos	Média por jogo
<i>TRB</i>	Total de rebotes	Média por jogo
<i>AST</i>	Assistências	Média por jogo
<i>STL</i>	Roubos de bola	Média por jogo
<i>BLK</i>	Tocos (bloqueios)	Média por jogo
<i>TOV</i>	Perdas de bola	Média por jogo
<i>PF</i>	Faltas cometidas	Média por jogo
<i>PTS</i>	Pontos	Média por jogo

Tabela 1 – Atributos do dataset






Figura 1 – Distribuição das variáveis numéricas




Figura 2 – Distribuição dos salários da NBA




Figura 3 – Correlação das variáveis com o salário

Com base na análise da Figura 3, observa-se que o *Salary* (salário) apresenta uma forte correlação positiva com métricas de volume, especificamente *PTS* (pontos), *MP* (minutos jogados) e *AST* (assistências). Esses dados sugerem que a remuneração na liga é fortemente influenciada pela capacidade de produção ofensiva e pelo tempo de permanência em quadra. Por outro lado, embora o *TOV* (turnovers) também apresente uma correlação com o salário, este atributo está mais intrinsecamente ligado aos minutos jogados do que ao valor financeiro em si; a lógica reside no fato de que jogadores com maior minutagem possuem, estatisticamente, mais oportunidades de cometer erros.

Adicionalmente, variáveis como *eFG%* (efetividade nos arremessos de quadra) e *Age* (idade) demonstram uma correlação linear menos acentuada com o salário. No entanto, essa baixa correlação linear não implica falta de relevância para a composição salarial. Pelo contrário, tais métricas podem exercer influências não lineares complexas: a eficiência (*eFG%*) pode ser o diferencial para contratos de valor máximo em jogadores de alto volume, enquanto a idade pode representar tanto o ápice físico quanto o valor de experiência em veteranos, fatores que o modelo de Redes Neurais busca capturar para além das regressões estatísticas simples.

4.2. PRÉ-PROCESSAMENTO DOS DADOS

Nesta etapa, o dataset será submetido a um processo de tratamento e refinamento, visando garantir que o modelo possa interpretar as variáveis de forma otimizada e inferir o salário dos atletas com a maior precisão possível, minimizando o erro. Inicialmente, procedeu-se à identificação e exclusão de atributos considerados irrelevantes ou prejudiciais para a tarefa de regressão, destacando-se:

- *Player* e *Team*: por se tratarem de campos de identificação nominal e categórica de alta cardinalidade, poderiam introduzir ruídos significativos, levando o modelo a memorizar nomes em vez de aprender padrões estatísticos;
- *ORB*, *DRB*, *FG*, *FGA*, *3P*, *3PA*, *2P*, *2PA*, *FT* e *FTA*: atributos considerados redundantes, uma vez que seus valores já estão sintetizados em métricas mais amplas;

- *FG%* e *2P%*: também descartados por redundância, visto que a métrica *eFG%* (Effective Field Goal Percentage) já oferece uma visão mais precisa da eficiência de arremesso ao ponderar o valor extra dos arremessos de 3 pontos.

Após a remoção seletiva desses atributos, o conjunto final de variáveis foi consolidado com: *Salary* (variável alvo), *Year*, *Pos*, *Age*, *G*, *GS*, *MP*, *3P%*, *eFG%*, *FT%*, *TRB*, *AST*, *STL*, *BLK*, *TOV*, *PF* e *PTS*.

Complementando o tratamento, foi aplicada uma transformação de dados nulos nas colunas numéricas, substituindo-os pelo valor 0. Essa abordagem é fundamentada na lógica de que a ausência de registro para determinadas estatísticas (como *3P%*, *eFG%* e *FT%*) indica a não ocorrência do evento, sendo o preenchimento por zero a representação mais fiel para o contexto esportivo.

Para mitigar a influência de outliers e evitar que o dataset fosse poluído por amostras de baixa significância estatística, foi implementado um filtro de volume de jogo. Jogadores com participação irrelevante na rotação das equipes poderiam distorcer as médias de eficiência; portanto, foram mantidos apenas atletas com mais de 10 jogos disputados na temporada e uma média mínima de 5 minutos por partida.

Além disso, em situações onde o jogador é listado atuando em múltiplas posições táticas no dataset, adotou-se a padronização de considerar exclusivamente a primeira posição informada, simplificando a codificação categórica sem perder a essência da função principal do atleta em quadra.

Uma das etapas mais críticas do pré-processamento deste dataset envolve o ajuste financeiro dos dados para lidar com a volatilidade econômica da liga. Ao analisar o intervalo entre as temporadas de 2017 e 2025, observa-se que a disparidade no teto salarial (*salary cap*) atinge a marca de quase 47 milhões de dólares, conforme registros da Basketball Reference³. Essa expansão financeira significa que um salário de 15 milhões de dólares em 2017 representava um impacto na folha de pagamento muito maior do que o mesmo valor nominal representaria em 2025.

Para garantir o máximo de precisão e permitir que o modelo realize comparações justas entre diferentes épocas, é imperativo neutralizar os efeitos da inflação esportiva. A solução adotada consiste em converter os salários de cada jogador em uma variável percentual, calculada

³ <https://www.basketball-reference.com/contracts/salary-cap-history.html>

em relação ao teto salarial vigente em sua respectiva temporada. Esta normalização transforma o “valor em dólar” em “fatia do orçamento”, permitindo que a rede neural identifique o real valor de mercado de um perfil estatístico, independentemente do ano em que os dados foram gerados. Com essa modificação, o modelo torna-se capaz de aprender padrões de remuneração escaláveis e consistentes, fundamentais para uma predição robusta.

Após isso, o dataset precisa ser separado em conjuntos de treinamento, validação e teste. Diferente de abordagens que utilizam sorteio aleatório, este trabalho adotou uma separação cronológica. Essa estratégia é fundamental em dados de séries temporais esportivas, pois evita o vazamento de dados, garantindo que o modelo não utilize informações do “futuro” para prever o passado. Para este estudo, a seguinte abordagem foi adotada:

- **Conjunto de treinamento (2017 a 2022):** compreende aproximadamente 66% dos dados totais. Este bloco robusto permite que a rede neural apreenda a diversidade de perfis estatísticos e as tendências de mercado consolidadas após a mudança de paradigma do jogo (ênfase em cestas de 3 pontos);
- **Conjunto de validação (2023 e 2024):** representando 22% do dataset, este conjunto é utilizado para o ajuste fino dos hiperparâmetros e para monitorar a perda (*loss*) durante o treinamento, prevenindo o *overfitting*;
- **Conjunto de teste (2025):** detém os 12% restantes, servindo como a prova final de generalização do modelo em dados inéditos e mais próximos da atualidade.

Seguindo esta separação rigorosa, é possível alcançar um modelo treinado de forma coerente de acordo com a sua temporada, permitindo identificar se a lógica de remuneração da liga permanece estável ou se novas discrepâncias surgiram nos dados mais recentes.

É importante ressaltar que a coluna *Year* perde sua utilidade para o modelo neste estágio. Uma vez que os dados foram segmentados por temporada e a remuneração foi convertida em um percentual relativo ao teto salarial vigente em cada ano, a variável temporal torna-se redundante. Consequentemente, sua exclusão pode ser realizada sem comprometer a integridade da análise.

Dada a natureza da distribuição dos salários na liga, observa-se a presença de caudas longas nos gráficos de distribuição, fenômeno impulsionado pela disparidade entre os contratos de nível mínimo e os salários máximos recebidos pelas estrelas da liga. Para mitigar essa assimetria e aproximar a distribuição de uma curva normal, o ideal é aplicar uma transformação logarítmica sobre a variável alvo (salário). Essa técnica visa deixar os dados melhor distribuídos,

reduzindo a variância e permitindo que o modelo de Deep Learning aprenda de forma mais estável, sem ser excessivamente influenciado pelos valores extremos dos atletas mais bem pagos da NBA.

Por fim, tendo em vista a diversidade de escalas nas variáveis numéricas e a presença de dados categóricos, a aplicação de técnicas de normalização e codificação tornou-se indispensável para que a arquitetura do modelo processe as informações de maneira eficaz. Para o tratamento dos atributos quantitativos, foi utilizado o *StandardScaler*, enquanto os atributos categóricos foram transformados por meio do *OneHotEncoder*. Ambos foram aplicados nos três conjuntos de dados (treinamento, validação e teste). Esses procedimentos contribuíram para a otimização da interpretação dos padrões contidos no conjunto de dados pelo modelo.

4.3. MODELAGEM E COMPILAÇÃO DO MODELO

Para a modelagem da rede neural, a biblioteca Keras foi adotada como interface principal, utilizando-se especificamente a *Model* (Functional API). A arquitetura foi estrategicamente estruturada em um formato de funil, composta por 5 camadas densas que reduzem gradualmente a dimensionalidade dos dados, conforme ilustrado na Figura 4 abaixo. As quatro primeiras camadas (desconsiderando a *input layer*), que atuam como camadas escondidas para extração de características, utilizam ReLU como função de ativação. Em contraste, a camada de saída utiliza a função Sigmoid, uma escolha deliberada para garantir que as previsões de salário (normalizadas como percentual do teto salarial) permaneçam estritamente dentro do intervalo entre 0 e 1.

O processo de compilação do modelo empregou o otimizador *Stochastic Gradient Descent* (SGD), configurado para minimizar a função de perda *Mean Squared Error* (MSE), que penaliza de forma mais rigorosa grandes desvios nas previsões salariais. Complementarmente, a métrica *Mean Absolute Error* (MAE) foi monitorada para fornecer uma interpretação humana mais direta e linear do erro médio absoluto cometido pelo sistema durante as fases de treinamento e validação.

Layer (type)	Output Shape	Param #
input_layer (InputLayer)	(None, 19)	0
dense (Dense)	(None, 128)	2,560
dense_1 (Dense)	(None, 64)	8,256
dense_2 (Dense)	(None, 32)	2,080
dense_3 (Dense)	(None, 8)	264
dense_4 (Dense)	(None, 1)	9

Figura 4 – Arquitetura do modelo

4.4. TREINAMENTO DO MODELO

Para o treinamento e ajuste fino da rede neural, definiu-se um ciclo de 100 épocas, permitindo que o algoritmo de otimização percorresse o conjunto de dados exaustivamente. A escolha do *batch size* fixado em 16 teve como propósito equilibrar a estabilidade da atualização do gradiente com a eficiência computacional, evitando oscilações bruscas na função de perda enquanto aproveita a regularização implícita de lotes menores para melhorar a generalização do modelo. Ao finalizar o treinamento com os conjuntos de treinamento e validação concatenados, o modelo apresentou métricas de desempenho altamente satisfatórias, obtendo um MSE de 0,0018 e um MAE de 3,02%.

4.5. AVALIAÇÃO DO MODELO

Por fim, a etapa de avaliação foi conduzida utilizando o conjunto de dados de teste, composto exclusivamente por registros da temporada de 2025. Esta fase é crucial para verificar a capacidade de generalização da rede neural em dados que não foram apresentados durante o treinamento ou o ajuste de hiperparâmetros. O modelo alcançou um desempenho final com um MSE de 0,0020 e um MAE de 3,18%.

Esta fase permite validar a robustez da arquitetura MLP em um ambiente que simula a aplicação real do modelo. Ao confrontar a rede neural com dados que representam a conjuntura

financeira mais recente da liga, assegura-se que a abordagem metodológica adotada é adequada para capturar a dinâmica contemporânea da NBA, demonstrando se o sistema é capaz de manter sua acurácia diante de variações estatísticas inéditas.

5. RESULTADOS

Os resultados consolidados revelam uma alta consistência no desempenho da rede neural. Durante a fase de treinamento e validação, o modelo obteve um MSE de 0,0018 e um MAE de 3,02%. Na avaliação final conduzida com o conjunto de teste (temporada de 2025), o sistema alcançou um MSE de 0,0020 e um MAE de 3,18%. Esse valor de MAE é particularmente expressivo, pois indica que, em média, as previsões de salário do modelo desviam apenas cerca de 3 pontos percentuais da fatia real do teto salarial que o jogador ocupa.

Quando o modelo prevê um salário muito acima, se deve ao fato de que provavelmente o jogador é subvalorizado, como é o caso de contratos de calouros (cerca de 600 mil dólares). Por outro lado, quando a previsão é abaixo do esperado, possivelmente é um jogador que se lesionou ou que assinou contrato máximo anos antes, e que nesta temporada jogou mal.

O presente modelo, apesar dessas discrepâncias pontuais causadas por fatores externos à quadra, é capaz de generalizar bem o comportamento da liga. Ao isolar o rendimento real das distorções financeiras e regras de teto salarial, esta rede neural prova sua utilidade como uma ferramenta capaz de identificar eficiências e ineficiências no mercado de jogadores da NBA.

A pequena variação entre as métricas de treino e teste demonstra que a arquitetura desenvolvida não sofreu de *overfitting* e é capaz de lidar com a dinâmica financeira da liga com alta confiabilidade. Considerando a alta volatilidade e os diversos fatores subjetivos que regem as negociações na NBA, um erro médio desta magnitude demonstra que a rede neural foi capaz de extrair padrões sólidos e generalizáveis a partir das métricas de desempenho fornecidas.

Portanto, o sistema valida sua utilidade como uma ferramenta objetiva para identificar ineficiências de mercado e calcular o salário justo baseado na produtividade estatística real dos atletas.